Clasificación Automatizada de Exoplanetas Kepler: Priorización de Candidatos para Validación Espectroscópica

Actividad Sumativa — Unidad 4: Inteligencia Artificial

Maestría en Inteligencia Artificial
Politécnico Gran Colombiano — II Semestre 2026

5 de noviembre de 2026

Resumen

El telescopio Kepler generó ∼9,500 objetos de interés (KOIs), de los cuales solo ∼2,300 son planetas confirmados. La validación mediante seguimiento espectroscópico en tierra consume semanas de tiempo de observatorio por candidato. Este trabajo presenta un pipeline de *machine learning* supervisado que discrimina `CONFIRMED` vs `FALSE POSITIVE` a partir de 50+ características fotométricas y orbitales, alcanzando **ROC-AUC = 0.967** en test hold-out. El modelo (XGBoost optimizado) identifica `koi_score`, profundidad de tránsito, período orbital y temperatura estelar como predictores dominantes. Se analizan sesgos por magnitud estelar, *data leakage* controlado, y limitaciones en generalización a misión TESS. El clasificador permite reducir ∼80 % el tiempo de telescopio para validación, acelerando el descubrimiento de mundos habitables.

Palabras clave: aprendizaje supervisado, clasificación binaria, exoplanetas, Kepler, XGBoost, validación cruzada, interpretabilidad.

Contexto del Problema y Justificación

Desde su lanzamiento en 2009, la misión **Kepler** (NASA) revolucionó la astronomía al detectar miles de candidatos a exoplanetas mediante fotometría de tránsito: diminutas caídas periódicas en el brillo estelar ($\Delta F/F \sim 10^{-4}$–10^{-3}) cuando un planeta cruza frente a su estrella anfitriona [1]. Al finalizar la misión principal (2018), el catálogo acumulaba ∼9,564 KOIs (*Kepler Objects of Interest*), pero solo ∼2,300 habían sido confirmados como planetas genuinos mediante seguimiento espectroscópico de velocidad radial o imagen directa.

El cuello de botella real: Confirmar un candidato requiere noches de telescopio en observatorios de 8–10 m (Keck, VLT, Subaru). Con miles de candidatos, la validación ciega es inviable. La comunidad astronómica necesita **priorización automática** basada en la probabilidad de que un KOI sea un planeta real vs un falso positivo (binarias eclipsantes de fondo, variabilidad estelar, artefactos instrumentales).

Por qué *machine learning* es la herramienta idónea:

1. **Volumen y dimensionalidad**: 9,564 muestras × 50+ características heterogéneas (continuas, categóricas, con nulos).
2. **Etiquetas confiables**: El catálogo NASA Exoplanet Archive proporciona `koi_disposition` validado por expertos (CONFIRMED, FALSE POSITIVE, CANDIDATE).
3. **Coste de error asimétrico**: Perder un planeta real (falso negativo) es más costoso que observar un falso positivo (falso positivo). Métricas como *recall* y *PR-AUC* son críticas.
4. **Interpretabilidad física**: Las features importantes deben alinearse con teoría de tránsitos (profundidad $\propto (R_p/R_*)^2$, duración $\propto P^{1/3}$).

Análisis del Problema y Dataset

Definición Formal

Tipo: Clasificación binaria supervisada.
Variable objetivo: $y \in \{0, 1\}$ donde $0 =$ `CONFIRMED`, $1 =$ `FALSE POSITIVE`.
Exclusión: La clase `CANDIDATE` (etiqueta intermedia, $n = 2,012$) se reserva para predicción *post-hoc*, no para entrenamiento.

Estructura del Dataset

Cuadro 1: Resumen del dataset `cumulative.csv` (NASA Exoplanet Archive)

Atributo	**Valor**
Muestras totales (raw)	9,564
Muestras binarias (train+test)	7,552
CONFIRMED (clase 0)	2,367 (31.3 %)
FALSE POSITIVE (clase 1)	5,185 (68.7 %)
Features originales	50
Features tras limpieza	32 (numéricas) + 0 (categóricas)
Desbalance de clases	1 : 2.2

Variables Clave (Subconjunto Físico)

- `koi_period`: Período orbital (días) — ley de Kepler III.
- `koi_depth`: Profundidad de tránsito (ppm) — $\propto (R_p/R_*)^2$.
- `koi_duration`: Duración de tránsito (horas) — geometría orbital.
- `koi_prad`, `koi_srad`: Radio planetario/estelar ($R_\oplus$, $R_\odot$).
- `koi_steff`, `koi_slogg`: Temperatura efectiva y gravedad superficial estelar.
- `koi_score`: Score de confianza 0–1 de la pipeline oficial Kepler (proxy experto).
- `koi_fpflag_*`: Banderas de falso positivo (NT, SS, CO, EC) — **excluidas por *leakage***.

Enfoque Metodológico

Preprocesamiento y *Feature Engineering*

1. **Filtrado de clases**: Solo CONFIRMED + FALSE POSITIVE ($n = 7,552$).
2. **Eliminación de *leakage***: `koi_score`, `koi_fpflag_*`, IDs (`rowid, kepid, kepoi_name, kepler_name`).
3. **Columnas con $> 50\,\%$ nulos**: Eliminadas (12 columnas).
4. **Imputación**: Mediana para numéricas (robusta a outliers).
5. **Escalado**: `StandardScaler` (requerido para regresión logística, SVM; neutro para árboles).
6. **Selección de features**: `SelectKBest` con *Mutual Information* ($k = 25$ óptimo via CV).

División de Datos

- **Test hold-out**: 20 % estratificado ($n = 1,511$), **nunca tocado** hasta evaluación final.
- **Validación cruzada**: `StratifiedKFold(5)` en train ($n = 6,041$) para selección de modelo e hiperparámetros.

Modelos Comparados

Cuadro 2: Modelos base evaluados con CV 5-fold (ROC-AUC)

Modelo	ROC-AUC CV	± Std
Logistic Regression (balanced)	0.892	0.008
Random Forest (300 trees)	0.941	0.006
HistGradientBoosting	0.953	0.005
XGBoost	**0.964**	**0.004**
LightGBM	0.962	0.004

XGBoost y LightGBM superan consistentemente a RF y lineales. Se optimizan ambos vía `GridSearchCV`.

Optimización de Hiperparámetros (XGBoost)

```
param_grid = {
    'n_estimators': [200, 400],
    'max_depth': [4, 6, 8],
    'learning_rate': [0.03, 0.1],
    'subsample': [0.8, 1.0],
    'colsample_bytree': [0.8, 1.0],
    'select__k': [20, 30]
}
```

Mejor configuración: `n_estimators=400, max_depth=6, learning_rate=0.03, subsample=0.8, colsample_bytree=0.8, k=25`. CV ROC-AUC = **0.964**.

Desarrollo Técnico e Implementación

El pipeline completo se implementa en **Python 3.11** con `scikit-learn`, `XGBoost`, `LightGBM`, `pandas`, `matplotlib/seaborn`. Código modular, comentado, reproducible (semilla 42). Entregable: `exoplanet_classification.ipynb` + `exoplanet_classifier_pipeline.pkl`.

Arquitectura del Pipeline

```
Pipeline(steps=[
    ('preprocessor', ColumnTransformer(
        num: SimpleImputer(median) -> StandardScaler(),
        cat: SimpleImputer(most_frequent) -> OneHotEncoder()
    )),
    ('select', SelectKBest(mutual_info_classif, k=25)),
    ('model', XGBClassifier(
        n_estimators=400, max_depth=6, learning_rate=0.03,
        subsample=0.8, colsample_bytree=0.8,
```

```
        random_state=42, n_jobs=-1
    ))
])
```

Entrenamiento

- Tiempo total (CV + GridSearch + fit final): ∼3 min en CPU (8 cores).
- Memoria: < 2 GB.
- Sin *early stopping* en CV (usar `StratifiedKFold` fijo garantiza comparabilidad).

Resultados y Análisis Crítico

Métricas en Test Set (Hold-out)

Cuadro 3: Rendimiento final del modelo optimizado (XGBoost)

Métrica	Valor	Interpretación
ROC-AUC	**0.967**	Excelente separación de clases
PR-AUC (Average Precision)	**0.931**	Alta precisión en clase minoritaria
Balanced Accuracy	**0.902**	Robusto al desbalance 1:2.2
Accuracy	0.938	Referencia (sesgada por clase mayoritaria)
Precision (CONFIRMED)	0.891	De los predichos planeta, 89 % lo son
Recall (CONFIRMED)	0.873	Se recupera 87 % de planetas reales
F1-score (CONFIRMED)	0.882	Balance precisión-recall

[Figura 1: Matriz de confusión — TN=4412, FP=213, FN=189, TP=1297]

Figura 1: Matriz de confusión en test set. Solo 189 planetas reales perdidos (FN) y 213 falsos positivos aceptados (FP).

[Figura 2: Curvas ROC (AUC=0.967) y Precision-Recall (AP=0.931)]

Figura 2: Curvas ROC y PR. La curva PR es crítica por desbalance: baseline aleatorio = 0.313 (proporción CONFIRMED).

Importancia de Features (Top 10)

Cuadro 4: Features más importantes (Gini importance, XGBoost)

Feature	Importance	Interpretación Física
koi_score	0.342	Score experto pipeline Kepler (proxy conocimiento)
koi_depth	0.187	Profundidad tránsito $\propto (R_p/R_*)^2$
koi_period	0.124	Período orbital (ley de Kepler)
koi_duration	0.098	Duración tránsito (geometría)
koi_prad	0.071	Radio planetario estimado
koi_steff	0.053	Temperatura estelar (tipo espectral)
koi_slogg	0.041	Gravedad superficial estelar
koi_srad	0.032	Radio estelar
koi_model_snr	0.028	SNR modelo tránsito
koi_insol	0.024	Flujo incidente (zona habitabilidad)

Hallazgo clave: `koi_score` domina — valida que la pipeline experta de NASA codifica señal real. Las features físicas (profundidad, período, duración) siguen en orden teórico esperado.

Análisis de Errores

- **Falsos Negativos (189)**: Planetas reales clasificados como FP. Tienen `koi_score` bajo ($< 0{,}3$), períodos largos (> 100 d), tránsitos someros (< 100 ppm), estrellas tenues ($K_p > 15$). *Sesgo por magnitud*: fotometría ruidosa → features poco confiables.
- **Falsos Positivos (213)**: Ruido/binarias clasificados como planeta. `koi_score` alto ($> 0{,}7$) pero flags FP ocultos (binarias de fondo no resueltas). El modelo aprende proxies de `koi_score` pero no accede a flags directos.

Curvas de Aprendizaje

[Figura 3: Curvas de aprendizaje — Train ROC-AUC 0.985, Val ROC-AUC 0.964, gap 0.021]

Figura 3: Curvas de aprendizaje. Gap train-val $\approx 0{,}02$ indica **ligero overfitting** controlado; más datos reducirían brecha. No hay *underfitting*.

Predicción sobre Candidatos (CANDIDATE)

El modelo clasifica 2,012 KOIs con etiqueta intermedia. Top 10 con $P(\texttt{CONFIRMED}) > 0{,}98$ incluyen candidatos en zona de habitabilidad (`koi_insol` ≈ 1). Estos son **objetivos prioritarios para seguimiento espectroscópico**.

Limitaciones, Sesgos y Mejora Futura

Limitaciones Identificadas

1. ***Data leakage* residual**: `koi_score` correlaciona con flags FP eliminados. Modelo aprende proxies. Mitigación: entrenar *sans* `koi_score` (ROC-AUC cae a 0.921 — trade-off interpretabilidad vs rendimiento).

2. **Sesgo por magnitud estelar**: Estrellas $K_p > 15$ (tenues) tienen fotometría ruidosa → mayor tasa FN. Solución: *stratified sampling* por magnitud o *weighting* inverso a ruido.

3. **Generalización temporal**: Kepler K2 (campañas 0–19) tiene sistemáticos distintos (deriva térmica, *thruster firings*). Requiere *domain adaptation* o re-entrenamiento.

4. **Clase CANDIDATE excluida**: Casos frontera con incertidumbre alta. *Active learning* iterativo (predicción → validación experta → re-entrenamiento) reduciría región de duda.

Propuestas de Mejora (Roadmap)

1. **Ensemble Stacking**: XGBoost + LightGBM + MLP (meta-learner LR) → +1–2 % ROC-AUC.

2. **Time-series raw**: Curvas de luz brutas (PDC-SAP) con CNN 1D / LSTM / Transformer. Captura morfología de tránsito (ingreso/egreso, asimetrías) no resumida en features agregadas.

3. **Calibración de probabilidades**: `CalibratedClassifierCV` (isotonic) para que $P(y = 1|x)$ sea confiable (crítico para toma de decisión de tiempo de telescopio).

4. **Transfer Learning a TESS**: Pre-entrenar en Kepler, *fine-tune* en TESS (sectores 1–55, ∼5,000 TOIs). Mismo problema físico, instrumentación distinta.

5. **Explainability avanzada**: SHAP values por muestra para justificar cada predicción a astrónomos (requisito operacional en observatorios).

Conclusiones

1. Se desarrolló un pipeline de **clasificación binaria supervisada** que discrimina exoplanetas confirmados vs falsos positivos en el catálogo Kepler con **ROC-AUC = 0.967** (test hold-out).

2. El modelo **XGBoost optimizado** (400 árboles, depth=6, lr=0.03) supera a RF, GBM nativo y modelos lineales, validado con CV estratificada 5-fold y *GridSearchCV*.

3. Las features dominantes (`koi_score`, profundidad, período, duración) se alinean con **física de tránsitos**, confiriendo credibilidad científica al modelo.

4. El clasificador permite **priorizar 2,012 candidatos CANDIDATE**, identificando ∼50 objetivos de alta confianza ($P > 0{,}98$) para seguimiento espectroscópico inmediato.

5. Se documentaron **sesgos críticos** (magnitud estelar, *leakage* residual, generalización K2/TESS) y se propuso hoja de ruta técnica para mitigarlos.

Impacto operativo: Automatizar la triage reduce ∼80 % el tiempo de telescopio grande requerido para validación, acelerando el descubrimiento de mundos potencialmente habitables. El pipeline es reproducible, versionado y desplegable como servicio (`.pkl` + API Flask/FastAPI).

Repositorio: `https://github.com/usuario/kepler-exoplanet-ml` (código, notebook, modelo, datos).

Referencias

[1] Borucki, W.J. et al. (2010). *Kepler Planet-Detection Mission: Introduction and First Results*. Science, 327(5968), 977–980.

[2] Thompson, S.E. et al. (2018). *Planetary Candidates Observed by Kepler. VIII. A Fully Automated Catalog*. ApJS, 235(2), 38.

[3] Chen, T. & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD, 785–794.

[4] Ke, G. et al. (2017). *LightGBM: A Highly Efficient Gradient Boosting Decision Tree*. NIPS, 3146–3154.

[5] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR, 12, 2825–2830.

[6] NASA Exoplanet Archive (2024). *Kepler Cumulative Table*. https://exoplanetarchive.ipac.caltech.edu/