

Lectura fundamental

Aprendizaje de máquinas: fundamentos

Módulo: Inteligencia Artificial

Unidad 4



Contenido

1 Introducción

2 Conceptos básicos de aprendizaje automático

3 Problemas y algoritmos de aprendizaje supervisado

4 Problemas y algoritmos de aprendizaje no supervisado

5 Conclusiones

Palabras clave: aprendizaje automático, inteligencia artificial, datos, modelos, algoritmos.

1. Introducción

¿Sabía usted que, cuando Netflix le recomienda una serie o cuando su asistente virtual reconoce su voz y responde, está observando en funcionamiento el aprendizaje automático? Esta disciplina, en constante evolución desde la década de 1960, se emplea ampliamente en diversas aplicaciones. Sin embargo, rara vez se es plenamente consciente de su uso, ya que suele operar en cuestión de segundos. De hecho, con la aparición de las redes sociales y la explosión de datos, la inteligencia artificial ha incrementado exponencialmente su aplicación en múltiples campos. Millones de datos son analizados con el fin de extraer información valiosa que contribuye a la toma de decisiones y al desarrollo de soluciones comerciales.

Pero, ¿cómo es posible que una máquina sea capaz de detectar patrones sin que se le indique explícitamente qué debe buscar? ¿Qué tipos de aprendizaje existen? En esta unidad se abordarán dichas preguntas, partiendo de los fundamentos esenciales y ejemplificando su uso a través de aplicaciones reales.

Como preámbulo, es importante tener presente que los componentes fundamentales del aprendizaje automático son los datos, los modelos y los algoritmos. A lo largo de este módulo, estos conceptos han sido tratados; no obstante, en este nuevo contexto se presentará su definición formal, su interrelación y sus implicaciones técnicas, las cuales serán discutidas en profundidad en la lectura asignada.

Sin lugar a duda, el aprendizaje automático tiene aplicaciones en múltiples industrias. Tal vez el campo en el que ha generado un mayor impacto social sea el de la medicina, donde contribuye a mejorar el diagnóstico clínico y permite la personalización de tratamientos. El desarrollo de dispositivos para intervenciones quirúrgicas o la detección de enfermedades mediante el análisis de imágenes son algunos de los ejemplos más avanzados del uso de esta tecnología.

Por otra parte, en el sector financiero, el aprendizaje automático resulta útil en la detección de fraudes y en la gestión de riesgos. Como se mencionó al inicio, sus aplicaciones son prácticamente ilimitadas. Los agentes inteligentes son capaces de resolver ciertos tipos de problemas; y, mediante el enfoque de aprendizaje automático, estos agentes adquieren la capacidad de enfrentar tareas considerablemente más complejas y desafiantes.

2. Conceptos básicos del aprendizaje Automático

Es sumamente importante adoptar una perspectiva global que considere tres conceptos fundamentales que serán analizados a lo largo de este contenido: inteligencia artificial, aprendizaje de máquinas y aprendizaje profundo.

Comencemos por la definición de inteligencia artificial (IA, por sus siglas en español; AI, por sus siglas en inglés). Esta se refiere al desarrollo de sistemas capaces de reproducir capacidades propias del pensamiento humano, como aprender, razonar y resolver problemas. Según Shinde y Shah (2018, p. 1), se trata de hacer que las máquinas sean tan inteligentes como el cerebro humano, transfiriendo la capacidad humana de aprendizaje y razonamiento a los dispositivos computacionales.

Como podrá notar, esta definición es lo suficientemente amplia como para abarcar aproximaciones ya abordadas en unidades anteriores. Por ejemplo, los agentes autónomos que, mediante algoritmos de búsqueda, resuelven tareas complejas, pueden entenderse como una manifestación clásica de la inteligencia artificial.

En segundo lugar, de acuerdo con Shinde y Shah (2018), el aprendizaje de máquinas o machine learning constituye un subcampo dentro de la inteligencia artificial. Este se enfoca en el desarrollo de algoritmos que permiten a las máquinas identificar patrones y resolver tareas complejas sin necesidad de ser programadas explícitamente para ello. Desde otra perspectiva, Murphy (2012) lo define como un conjunto de métodos capaces de detectar automáticamente patrones en los datos y emplearlos para predecir información futura o tomar decisiones en contextos de incertidumbre, como, por ejemplo, planificar la recolección de nuevos datos.

Por último, el aprendizaje profundo (*deep learning* o DL, por sus siglas en inglés) representa un subcampo del aprendizaje de máquinas, centrado específicamente en el desarrollo de algoritmos basados en redes neuronales artificiales. Estos algoritmos están diseñados para emular la forma en que el cerebro humano procesa información, permitiendo un análisis más profundo y automatizado de grandes volúmenes de datos.

La Figura 1 ilustra gráficamente estos tres niveles, siguiendo el orden de generalidad a especificidad. En otras palabras, el aprendizaje de máquinas es una de las formas mediante las cuales las máquinas intentan emular el aprendizaje y razonamiento humano, mientras que el aprendizaje profundo constituye una estrategia avanzada dentro de este enfoque.

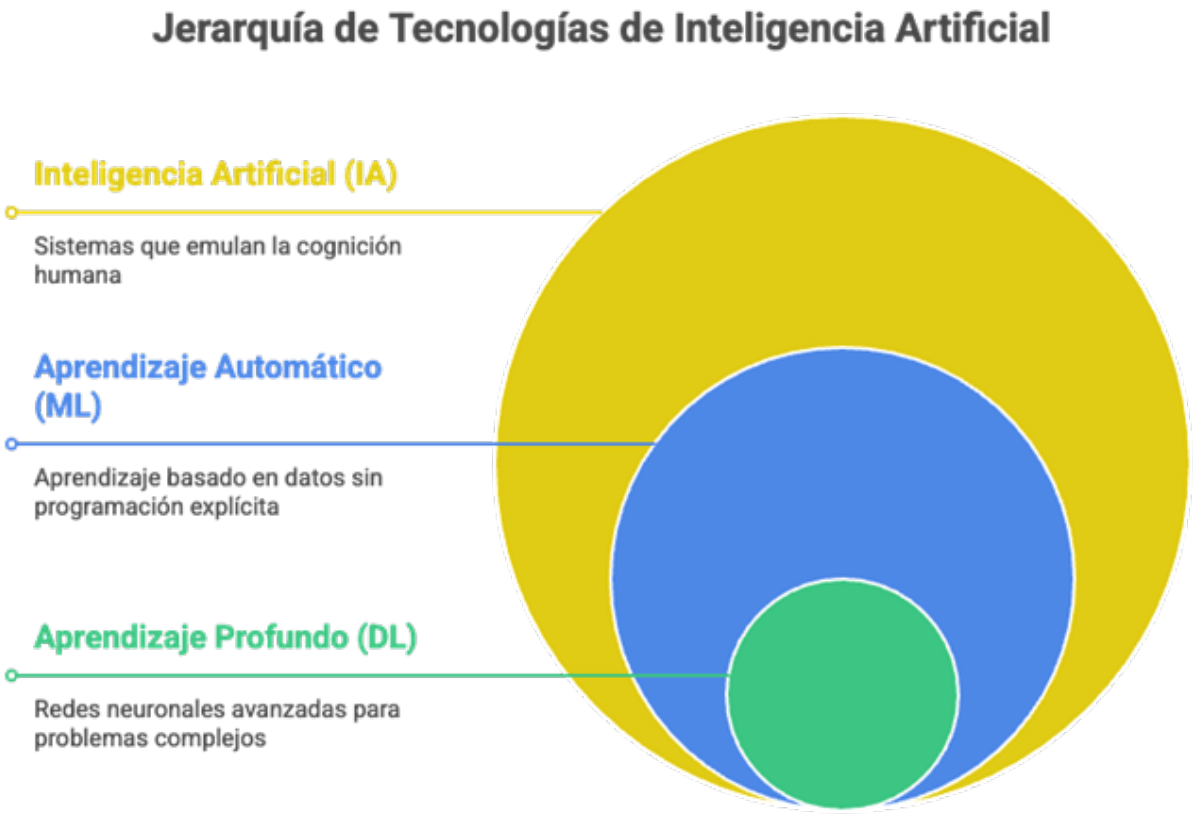


Figura 1. Jerarquía de la Inteligencia Artificial
Fuente: modificado de Shinde y Shah (2018)

El aprendizaje automático permite que los sistemas informáticos se ajusten y mejoren continuamente a medida que acumulan más *experiencia*. Por lo tanto, el rendimiento de estos sistemas puede mejorar si se proporcionan conjuntos de datos más grandes y variados para su procesamiento. Esta definición se encuentra alineada con las ideas de Mitchell, T. M. (1997), quien define el aprendizaje automático como el campo que se encarga de construir programas informáticos que mejoran automáticamente con la experiencia.

Tips

En entornos profesionales el aprendizaje automático es llamado tambien Machine Learning.

El aprendizaje automático se basa en tres componentes fundamentales que interactúan para permitir que las máquinas aprendan y realicen tareas predictivas: datos, modelos y algoritmos. Cada uno de estos componentes desempeña un papel crucial en el proceso de aprendizaje y predicción.

En el primer componente, los datos, existen 40 billones de páginas de internet indexadas, 100 horas de video son cargadas a YouTube cada minuto, Walmart gestiona más de un millón de transacciones por hora, es decir, 2.5 petabits en almacenamiento. Murphy K. P. (2012). Esa gran cantidad de información contiene dentro de sí, patrones valiosos que si no existieran métodos de análisis automatizas, a las personas más inteligentes les tomaría demasiado tiempo encontrar patrones de consumo, patrones de movimiento tratando de registrar y sacar métricas de todos los registros existentes de algún escenario mencionado, manejando incluso tipos de sesgo o errores manuales que no nos proporcionarían seguridad y contendrían la característica de incertidumbre muy elevada para la toma de decisiones.

2.1. Crecimiento exponencial de los datos

En décadas anteriores, la toma de decisiones en una empresa se establecía como un proceso racional en el que los directivos de las empresas tomaban decisiones recopilando, integrando y analizando datos de forma mecanicista, es decir, mediante procesos repetitivos y poco eficientes para la captura o almacenamiento de información (Saldaña Sánchez, 2021). Ahora los métodos de análisis le permiten tanto a directivos como a diferentes elementos dentro de una organización tomar decisiones basadas en el análisis en volúmenes de datos extremadamente grandes y que generan con una eficiencia mucho mayor resultados más eficientes y eficaces. Al eliminar algunos componentes humanos, tal como lo menciona Maldonato y Dell'Orco (2011), las diferencias individuales en el comportamiento de toma de decisiones no sólo están relacionadas con el nivel de experiencia del decisor, sino también con otras variables como los estilos cognitivo y motivacional, la edad, el sexo, el estatus socioeconómico y otras más.

La Figura 2 muestra la evolución de los ingresos del mercado global de centros de datos desde 2017 hasta 2030 en el que se puede evidenciar un crecimiento constante en los ingresos totales del sector de centros de datos, desde 286.41 mil millones en 2017 hasta una proyección de 759.95 mil millones en 2030. Esto nos permite intuir que la demanda de alojamiento y gestión de datos es una necesidad creciente a nivel global, para nuestro contexto esto se traduce en una necesidad de procesar, analizar y transformar dicha información en accionables que permitan tomar decisiones informadas.

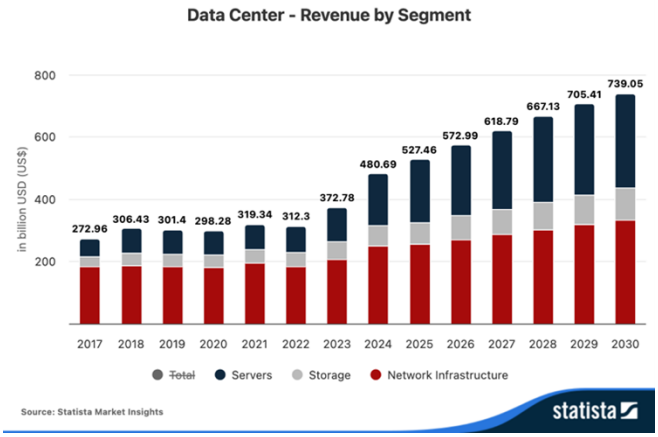


Figura 2. Centros de Datos – Ingresos por Segmento
Fuente: tomado de Statista (2025)

Los datos son la base del aprendizaje automático. Sin datos, los algoritmos no tienen nada que aprender. Los datos pueden ser estructurados, como bases de datos con columnas y filas, o no estructurados, como imágenes, texto o audio (Russell y Norvig, 2021). La calidad y cantidad de los datos son determinantes para el éxito de un modelo de aprendizaje automático. Los datos deben ser representativos del problema que se intenta resolver y estar libres de sesgos y errores (Hastie, Tibshirani, y Friedman, 2009). La preparación de los datos, que incluye limpieza, normalización y transformación, es un paso crítico antes de alimentar los datos a un modelo.

2.2. Modelos

Los modelos son representaciones matemáticas que permiten describir relaciones entre variables. Estas relaciones pueden ser simples, como una relación lineal, o mucho más complejas. Por ejemplo, una relación lineal sencilla podría darse en una empresa que vende helados: una mayor temperatura ambiente (en grados centígrados), mayor es la cantidad de helados vendidos.

Sin embargo, también es posible construir modelos más complejos al incorporar otras variables, como la estación del año, la localización de los puntos de venta o patrones temporales. El nivel de complejidad del modelo puede aumentar según la cantidad de variables que se deseen considerar y la naturaleza del fenómeno que se quiere representar.

De este modo entonces, un modelo es una representación matemática que un sistema de aprendizaje automático crea o construye a partir de los datos (Russell y Norvig, 2021). Considere el siguiente escenario, Imagine, por ejemplo, que usted es responsable de administrar el consumo de energía de un centro de datos. Como ya se ha mencionado, la demanda computacional crece año tras año, y lo hacen también los costos operativos y el impacto ambiental. El aprendizaje automático se presenta como una solución prometedora, para no tener que depender de reglas estáticas o fórmulas ingenieriles tradicionales (que suelen ser insuficientes ante sistemas complejos y dinámicos), los modelos de machine learning pueden aprender patrones no lineales a partir de grandes volúmenes de datos operacionales. Como lo demuestra el estudio de Google, este enfoque permitió predecir con alta precisión el indicador de eficiencia energética (PUE), optimizar configuraciones sin necesidad de pruebas físicas y reducir significativamente el consumo energético en sus centros de datos (Gao, 2014).

2.3. Algoritmos

Los algoritmos son los procedimientos o pasos que los modelos utilizan para aprender de los datos. Un algoritmo define cómo se ajustan los parámetros del modelo durante el proceso de entrenamiento (Bishop, 2006). Por ejemplo, el algoritmo de regresión lineal ajusta los coeficientes de la línea que mejor se ajusta a los datos. Los algoritmos de aprendizaje automático pueden ser supervisados, no supervisados o por refuerzo, dependiendo de si utilizan datos etiquetados, buscan patrones ocultos o aprenden mediante recompensas y castigos. El detalle de cómo funciona cada uno será abordado más adelante en la lectura.

A lo largo de los años se han popularizado una gran cantidad de algoritmos que han demostrado ser altamente versátiles, con aplicaciones en diversos campos como la medicina, las finanzas, la industria, entre muchos otros.

Recuerde que...

Mientras que la inteligencia artificial es una categoría amplia de la informática, el aprendizaje automático es una aplicación de la IA que implica entrenar sistmeas para que ejecuten una tarea sin estar programadas explicitamente para ella. El aprendizaje automático se encarga de extraer conocimiento de los datos a través de algoritmos que se encuentran categorizados en tres grandes grupos, aprendizaje supervisado, no supervisado y por refuerzo. Cada uno de estos grupos contiene multiples algoritmos.

En secciones posteriores de esta lectura, se abordarán con mucho más detalle los diferentes algoritmos disponibles en función del tipo de problema que se pretenda resolver.

3. Problemas y algoritmos del aprendizaje supervisado

En el **aprendizaje supervisado**, recuerde que los dos problemas tradicionales que se abordan son: la **regresión**, donde se busca estimar un valor numérico (continuo); y la **clasificación**, donde se pretende asignar una observación a una categoría o etiqueta previamente conocida. Ambos enfoques son fundamentales para comprender el propósito de estos algoritmos.

El objetivo es que un agente aprenda a aproximar una *función desconocida* a partir de un conjunto de ejemplos donde tanto la entrada como la salida son conocidas. Es decir, a partir de muchos pares de datos de entrada y salida (x, y), el sistema construye una función h (también conocida como hipótesis o modelo) que intenta replicar la verdadera función subyacente f(x), la cual generó los datos observados (Russell y Norvig, 2021).

Este tipo de aprendizaje tiene una característica propia que lo hace único, **un mecanismo claro de retroalimentación**. Esto quiere decir que el modelo recibe ejemplos con respuestas correctas (etiquetas), lo que le permite aprender conociendo los resultados esperados (Russell y Norvig, 2021). Por ejemplo, si se entrena un sistema para reconocer autobuses en imágenes, se le presentan muchas fotografías acompañadas de etiquetas que indican si aparece un autobús en la imagen. O por dar otro ejemplo, un vehículo autónomo podría aprender a frenar observando su velocidad y las condiciones del camino junto con la distancia real que tardó en detenerse.

Tabla 1. Ejemplo de conjunto de entrenamiento

Característica 1 (x_1)	Característica 2 (x_2)	Etiqueta (Y)
10	70	1
20	520	0
...	...	...
Característica 1 n	Característica 2 n	Etiqueta n

Fuente: elaboración propia

La Tabla 1 presenta un conjunto de datos con tres columnas. Las dos primeras, y , representan características o atributos de cada observación, mientras que la tercera columna, , corresponde a la etiqueta o variable objetivo que el modelo debe predecir.

En un conjunto de entrenamiento ideal, las características deben contener suficiente información para explicar o predecir el valor de Y. Para este caso, se trata de un modelo de clasificación binaria, donde la etiqueta Y toma valores finitos y bien definidos: 0 indica la ausencia de una característica y 1 su presencia.

Este tipo de clasificación puede aplicarse a múltiples escenarios **dicotómicos**, como predecir si es un buen momento para comprar una acción en el mercado bursátil, o identificar si una imagen corresponde a una vaca, según las características extraídas (x_1,x_2 , etc.).

Russell y Norvig (2021) argumentan que, en el contexto del aprendizaje automático, los algoritmos exploran dentro de un espacio de hipótesis (definido como H) para encontrar la función h que mejor se ajuste a los datos. Este espacio H puede variar según el tipo de problema, el conocimiento previo o el análisis exploratorio de los datos,

Como ya se ha mencionado, dentro del aprendizaje supervisado existen dos grandes tipos de problemas:

- **Clasificación**, cuando la salida es una **categoría** o **etiqueta** entre un número finito de clases (por ejemplo, ***autobús*** o ***peatón***).
- **Regresión**, cuando la salida es un valor numérico continuo u ordenado (por ejemplo, el precio de una casa o la distancia de frenado).

Importante...

Dado que existen ejemplos etiquetados que permiten conocer la respuesta o salida esperada (y) de un conjunto de variables (x), es una etapa fundamental del proceso de aprendizaje de maquinas supervisado definir adecuadamente la separación de los datos en grupos de entrenamiento y prueba.

Esta altamente extendido el uso del 80% o 70% del total de los datos como conjunto de datos de entrenamiento y el restante de prueba, sin embargo, como se verá mas adelante, existen técnicas que permiten eliminar sesgos que puedan existir dentro de los subconjuntos.

3.1. Generalización

Un aspecto clave es la capacidad del modelo para **generalizar**, es decir, para predecir correctamente en ejemplos nuevos que no ha visto antes. Para que esto sea posible, se asume que los datos futuros provienen de la misma **distribución de probabilidad** que los datos de entrenamiento, y que son independientes entre sí. Con lo que, además del **conjunto de entrenamiento**, se utiliza un **conjunto de prueba** para evaluar el desempeño del modelo en datos nuevos, y con frecuencia se recurre también a un **conjunto de validación** para ajustar parámetros sin sesgar la evaluación.

Para evitar el **sobreajuste** se aplican técnicas como la regularización, que buscan un equilibrio entre el error del modelo y su complejidad. Desde una perspectiva teórica, el aprendizaje computacional también ofrece marcos como el aprendizaje PAC, que brindan garantías sobre cuántos ejemplos se necesitan y qué tan buena puede ser una hipótesis aprendida.

3.2. Problemas de clasificación

Los algoritmos de aprendizaje supervisado están basados en modelos predictivos, los cuales están compuestos por dos grupos de datos uno para realizar el entrenamiento, otro de prueba y un mecanismo que permita evaluar si el algoritmo está *aprendiendo* correctamente. El conjunto de datos previamente etiquetado (del cual ya se sabe a qué grupo, valor o categoría pertenecen) son los datos de entrenamiento y son utilizados para realiza el ajuste al modelo, los datos son utilizados por el algoritmo para ir *aprendiendo* a clasificar las muestras realizando una comparación del resultado obtenido por el modelo, y el valor inicial de la muestra, realizando compensaciones con respecto al modelo y a cada error en la estimación del resultado.

Distribución de probabilidad

Una distribución de probabilidad es una asignación de una probabilidad para cada valor posible de una variable aleatoria.

Tips

Existen muchas formas en las que los modelos pueden aprender sobre un conjunto de datos, sin embargo, por practicidad la definición anterior puede ayudarle a hacerse una idea de como estos modelos aprenden. A lo largo de la lectura se irá refinando este concepto a medida que se presentan algoritmos especificos.

El aprendizaje automático aborda una variedad de problemas, entre los cuales la clasificación y la regresión son dos de los más comunes. Ambos problemas implican el uso de algoritmos para hacer predicciones basadas en datos, pero difieren en el tipo de predicción que realizan.

Los **problemas de clasificación** es un tipo de problema en el que el objetivo es asignar una etiqueta o categoría a un conjunto de datos. Los algoritmos de clasificación analizan las características de los datos de entrada y determinan a qué clase pertenecen. Este tipo de problema es común en situaciones donde se necesita categorizar datos en grupos discretos. Por ejemplo, en el diagnóstico médico, los algoritmos de clasificación pueden utilizarse para determinar si una imagen de rayos X muestra signos de cáncer o no (Esteva *et al*., 2017). Otros ejemplos incluyen la clasificación de correos electrónicos como spam o no spam, y la identificación de objetos en imágenes.

Como se mencionó anteriormente, es indispensable contar con un conjunto de datos de entrenamiento que cuente con los suficientes ejemplos para capturar las relaciones de las variables predictoras (o características) con la de la variable objetivo (o variable dependiente). Esto aplica para ambos casos, tanto clasificación como regresión.

3.2.1. Ajuste óptimo

El objetivo es encontrar el *ajuste óptimo*, donde se pretende encontrar una hipótesis (**modelo**) que se ajuste lo mejor posible a los datos de entrenamiento. Esto suele definirse como la minimización de la *tasa de error*, que no es más que la proporción de veces que la predicción del modelo no coincide con la etiqueta verdadera de un ejemplo (Russell y Norvig, 2021).

Por esta razón es indispensable que el conjunto de entrenamiento:

1. Se ajuste lo mejor posible a la realidad del contexto que se pretende resolver a través del modelo.
2. Debe contener la mayor cantidad posible de variaciones o ejemplos, de modo que la función aprendida durante el entrenamiento pueda **generalizar** adecuadamente. Esto se logra al exponer el modelo a una amplia diversidad de casos, lo que le permite refinar la función que describe la relación entre la variable dependiente y las variables independientes.

En enfoques más sofisticados, implica minimizar una **función de pérdida**, que cuantifica el *coste* de los distintos tipos de errores de predicción. Por ejemplo, clasificar erróneamente como spam lo que no es spam podría considerarse una pérdida mayor que clasificar erróneamente como spam lo que no es spam.

3.2.2. Resumen

En resumen, los problemas de clasificación son aquellos en los que se requiere predecir una categoría o etiqueta finita y muy bien definida, pueden ser problemas de clasificación binaria o multiclase. En primer lugar, los problemas de clasificación dicotómicas (conocidas como binarias), existen solamente dos valores que pueden tomar, existe una característica o no existe. Comúnmente, en el conjunto de datos de entrenamiento la variable a predecir se encuentra como unos o ceros. En segundo lugar, es posible tener problemas de clasificación multiclase, en los que se tienen más de dos estados o etiquetas a predecir.

3.3. Problemas de regresión

La regresión se utiliza para predecir valores continuos. En problemas de regresión, el objetivo es encontrar una función que relacione las variables de entrada con una variable de salida continua. Este tipo de problema es común en situaciones donde se necesita predecir cantidades numéricas. Por ejemplo, en el sector financiero, los modelos de regresión pueden utilizarse para predecir el precio de las acciones en función de variables económicas (Ngai *et al*., 2011). Otros ejemplos incluyen la predicción de la temperatura en función de datos meteorológicos y la estimación de la demanda de productos en función de tendencias de mercado.

En la Figura 3 se puede observar distintos tipos de relaciones lineales entre dos variables, en problemas de regresión es uno de los primeros conceptos que permite comprender las relaciones lineales entre un conjunto de variables. En la primera imagen (arriba a la izquierda) se muestra una **correlación** positiva fuerte, esto significa que a medida que X aumenta, Y también lo hace de forma bastante predecible.

Correlación

Evalua qué tan relacionadas están dos variables, si una aumenta cuando la otra también lo hace, hay una correlación positiva.
En el caso contrario sería un correlación negativa.

Por otro lado, en la parte superior derecha hay una correlación positiva débil, donde también hay una tendencia ascendente, pero con mayor dispersión entre los puntos. Abajo a la izquierda aparece una correlación negativa fuerte, donde un aumento en X implica una disminución clara en Y. Finalmente, en la última imagen (abajo a la derecha), no hay una relación aparente entre las variables; este caso representa una correlación nula.

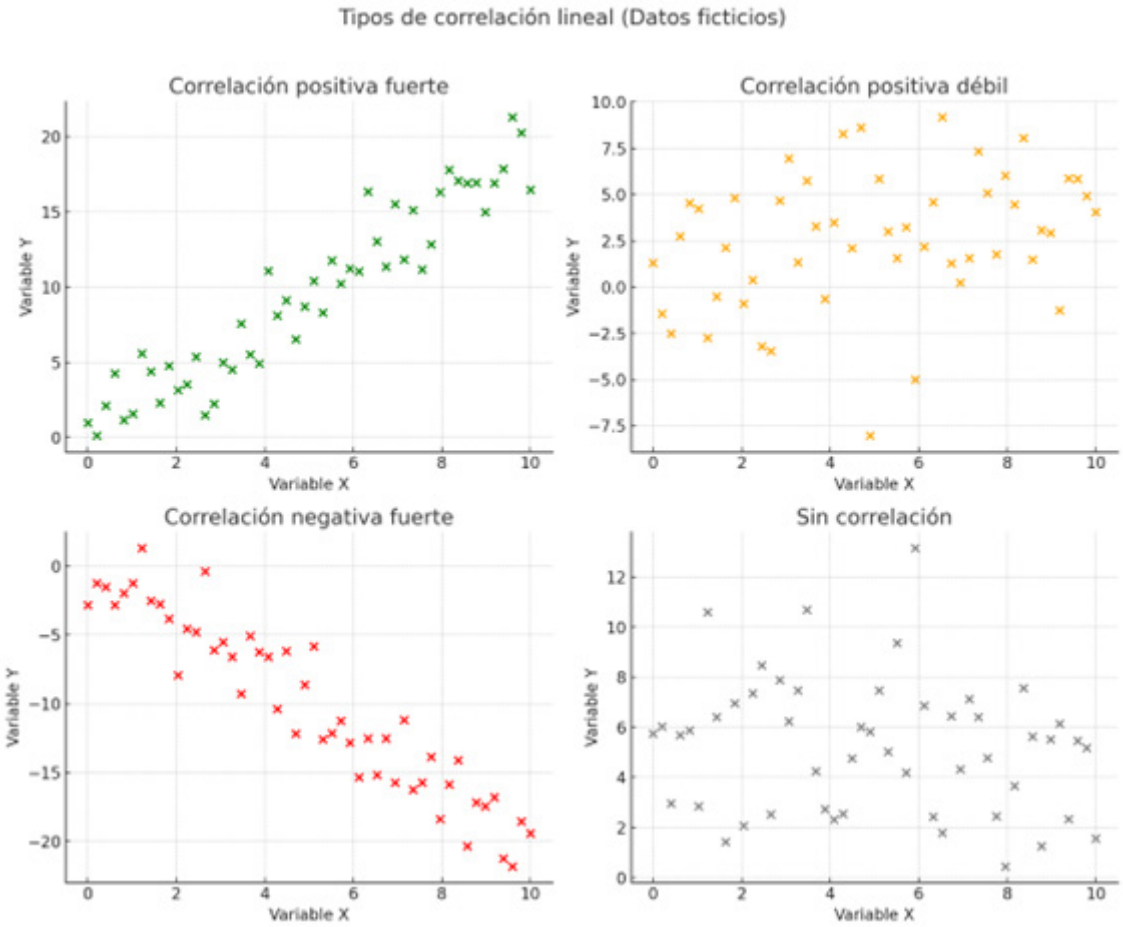


Figura 3. Tipos de correlación
Fuente: elaboración propia

Identificar visualmente este tipo de patrones ayuda a desarrollar intuición sobre cuándo puede tener sentido aplicar modelos lineales, y cuándo podría ser necesario explorar alternativas más complejas.

Volviendo sobre la Figura 3, los modelos de regresión son la representación matemática (a través de una función) que tiene el menor error posible (menor diferencia posible entre el valor real y el valor predicho) sobre el conjunto de entrenamiento. La regresión lineal es un método estadístico que se utiliza para modelar la relación entre una variable dependiente y una o más variables independientes, bajo el supuesto de que esa relación puede representarse mediante una línea recta. En su forma más simple, permite predecir el valor de una variable (por ejemplo, el ingreso) a partir de otra (como los años de educación).

Según Géron (2019), este tipo de regresión intenta encontrar la línea recta que mejor se ajusta a los datos, minimizando la distancia entre los valores reales y los valores predichos. La ecuación típica de la regresión lineal simple es:

$$Y = \beta_0 + \beta_1 X + \epsilon$$

donde Y es la variable dependiente, X es la variable independiente, β_0 es el intercepto, β_1 es la pendiente, y ϵ es el término de error.

Cómo mejorar...

Dentro de las referencias de esta lectura existen multiples recursos que cubren a mayor profundiad la parte matemática detrás de muchos de los algoritmos presentados, se recomienda revisarlos para cubrir los capitulos relacionados con el contexto matemático e implementaciones para tener una visión mucho mas detallada del flujo de entrenamiento.

Al igual que los problemas de clasificación, el conjunto de datos de entrenamiento debe ser lo suficientemente variado para encontrar una función que explique el comportamiento de la variable numérica (y).

Ambos problemas, clasificación y regresión, son fundamentales en el aprendizaje automático y tienen aplicaciones en diversas industrias. La elección entre un modelo de clasificación o regresión depende del tipo de datos y del objetivo de la predicción. Los avances en algoritmos y técnicas de aprendizaje automático han mejorado significativamente la precisión y eficiencia de los modelos para abordar estos problemas, permitiendo a las organizaciones tomar decisiones más informadas y optimizar sus operaciones.

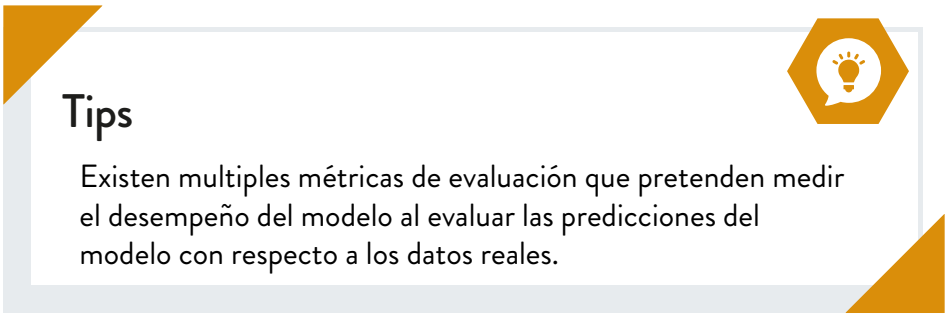
3.4. Regularización

La **regularización** es un concepto que se utiliza para evitar el **sobreajuste** (overfitting) de los modelos a los datos de entrenamiento y, esto genera una mejorar en su capacidad de generalización a nuevas observaciones. Según Russell Y Norvig (2021), ese penaliza la complejidad del modelo durante el proceso de entrenamiento. Al añadir un término de penalización a la función de pérdida (o de coste) que el modelo intenta minimizar.

Los pasos fundamentales de la penalización son:

3.4.1. Pérdida y penalización

En general, un algoritmo de aprendizaje busca encontrar una función que se ajuste bien a los datos de entrenamiento observados dados los inputs . Sin regularización, el objetivo principal es minimizar una función de pérdida (o error) que mide la diferencia entre las predicciones del modelo y los valores reales en el conjunto de entrenamiento, como el error cuadrático medio (MSE) en regresión.



Un modelo que se ajusta perfectamente a los datos de entrenamiento (minimizando el error a cero, por ejemplo) a menudo captura el ruido o las particularidades específicas de esos datos, en lugar de las relaciones subyacentes verdaderas (Russell & Norvig, 2021). Esto se conoce como **sobreajuste**. Para contrarrestar esto, la regularización introduce un equilibrio:

$$Costo(h) = EmpLoss(h) + \lambda Complexity(h)$$

El término representa el error empírico o la pérdida del modelo en los datos de entrenamiento.

El término es una función de regularización que cuantifica la complejidad del modelo. Un modelo más complejo (por ejemplo, con coeficientes grandes o muchas características) tendrá una penalización mayor.

λ *(lambda)* es un hiperparámetro de sintonización. Es un valor no negativo que controla la fuerza de la penalización.

- Si $\lambda = 0$, no hay penalización y el modelo se ajusta solo a los datos de entrenamiento, con riesgo de sobreajuste.
- Si λ es muy grande, la penalización es fuerte, forzando un modelo muy simple que podría **subajustarse** (Alto sesgo).

La elección de un λ óptimo permite balancear el ajuste a los datos y la complejidad del modelo.

3.4.2. El balance sesgo-varianza

La regularización influye directamente en el balance sesgo-varianza de un modelo. Un modelo con baja complejidad (mucha regularización, grande) tiende a tener un sesgo alto (no es lo suficientemente flexible para capturar la verdadera relación subyacente) pero una varianza baja (es más estable a los cambios en los datos de entrenamiento).

Un modelo con alta complejidad (poca o ninguna regularización, pequeño) tiende a tener un sesgo bajo (puede ajustarse bien a la verdadera relación) pero una varianza alta (es muy sensible a los datos de entrenamiento, lo que lleva al sobreajuste).

La regularización, al imponer una penalización, introduce un cierto sesgo adicional en las estimaciones de los coeficientes, pero a cambio reduce significativamente la varianza. Esto suele resultar en un menor error de predicción en los datos de prueba no vistos (error de generalización), que es el objetivo final. La Figura 4 permite analizar visualmente esta relación.

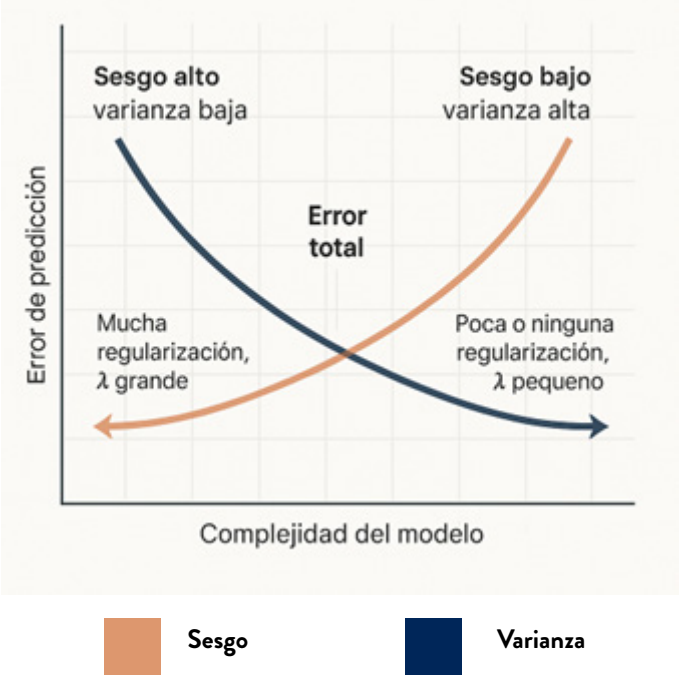


Figura 4. Balance sesgo-varianza
Fuente: elaboración propia.

El objetivo del análisis es encontrar el punto de menor error total, que ocurre en el equilibrio entre un sesgo aceptable y una varianza controlada, este menor error suele estar acompañado por una mezcla de valores finamente seleccionados. Justamente la forma en la que se seleccionan esos parámetros se les conoce común mente como ajuste de hiperparámetros.

3.5. Ajuste de hiperparámetros

El **ajuste de hiperparámetros** (o hyperparameter tuning en inglés) son parámetros de configuración externos a tu modelo (Russell y Norvig, 2021). No se aprenden directamente de los datos de entrenamiento a través del algoritmo de optimización del modelo (como sí lo hacen los coeficientes de una regresión o los pesos de una red neuronal). Sino que más bien, los hiperparámetros se establecen antes del proceso de entrenamiento y están más relacionados con la complejidad o la flexibilidad del modelo.

Hay una analogía muy usada para comprenderlo y está relacionada con la cocina, si fueras un chef intentando cocinar un rico ajiaco. La receta te dice los ingredientes y los pasos básicos (esto sería tu algoritmo de aprendizaje, como la regresión lineal o las redes neuronales). Pero hay ciertas *decisiones* que toma el cocinero (el científico de datos), ocurren antes de empezar a cocinar, y que afectarán el resultado final. Estos son los **hiperparámetros**.

Algunos ejemplos de hiperparámetros que mencionan Russell y Norvig (2021) son:

- λ (lambda): Controla la fuerza de la penalización de regularización en métodos como la Regresión Ridge (L2) y Lasso (L1). Este parámetro se explicó previamente.
- C (parámetro de coste): Es utilizado en un algoritmo llamado Máquinas de Vectores de Soporte (SVM). Controla el balance entre permitir errores en los datos de entrenamiento y mantener un margen amplio.
- Grados de libertad (df): En técnicas de suavizado como los smoothing splines o regression splines. Determina la suavidad o flexibilidad de la función ajustada. Un mayor número de grados de libertad permite una función más flexible y *ondulada*.
- Número de componentes principales (M): En la Regresión de Componentes Principales (PCR). Controla cuántas de las combinaciones lineales de características originales (componentes principales) se utilizan para la predicción.
- Número de iteraciones (M): En algoritmos de *boosting*. Controla cuántos *pequeños* modelos se combinan para formar el modelo final.

Boosting

Boosting es una metaheurística de conjunto que reduce principalmente el sesgo y que también puede mejorar la estabilidad y la precisión de los algoritmos de clasificación y regresión.

La función principal de los hiperparámetros es optimizar el rendimiento del modelo en datos no vistos, es decir, mejorar la capacidad de generalización. El principal propósito es encontrar el equilibrio óptimo en el balance sesgo-varianza.

Se usan estrategias para evaluar de manera imparcial los hiperparámetros. Existen multiples métodos populares para definirlos, la validación cruzada (*cross validation*) es uno ampliamente conocido.

3.6. Validación cruzada

Este es el método más común y robusto. Imagínelo como un proceso donde un estudiante (modelo) hace un examen varias veces, pero cada vez con un subconjunto diferente de preguntas (muestras) que no ha visto antes durante sus horas de estudio (entrenamiento). De ese modo, los datos de entrenamiento se dividen en k subconjuntos (llamados *folds*). El modelo se entrena k veces. En cada repetición, se usa un fold diferente como conjunto de ***validación*** (para probar el rendimiento del hiperparámetro), y los k-1 folds restantes se usan para el entrenamiento.

Se calcula el error de validación promedio para cada valor de hiperparámetro que se está probando. Finalmente, se elige el valor del hiperparámetro que resultó en el menor error de validación promedio. Una vez que se selecciona el hiperparámetro óptimo, el modelo se vuelve a entrenar usando todos los datos de entrenamiento y ese valor de hiperparámetro.



Figura 5. Ejemplo de validación cruzada
Fuente: tomado de MathWorks, (s.f.)

En la Figura 5 el conjunto de datos se divide en cuatro partes iguales. En cada iteración (Fold 1, Fold 2, etc.), una parte diferente se utiliza como conjunto de prueba (en amarillo), mientras que las otras tres se usan como conjunto de entrenamiento (en azul). Este proceso se repite cuatro veces, cambiando cada vez el bloque que se evalúa. Al final, se promedian los errores de cada pliegue () para obtener una estimación más confiable.

3.7. Algoritmos populares

Los algoritmos más habituales que aplican para el aprendizaje supervisado son:

- Árboles de decisión.
- Clasificación de Naïve Bayes.
- Regresión por mínimos cuadrados.
- Regresión logística.
- Support Vector Machines (SVM).
- Métodos *ensemble* (Conjuntos de clasificadores).

Cómo mejorar...

Dentro de las referencias de esta lectura existen multiples recursos que cubren a mayor profundiad el desarrollo conceptual de los algoritmos de aprendizaje automático, del mismo modo páginas como medium.com tienen disponible miles de ejemplos de implementaciones en multiples lenguajes, iterpretación de resultados y evaluación de modelos. Invito a que active su curiosidad intelectual para profundizar en lo expuesto en esta lectura.

3.8. Aplicaciones y retos

Uno de los principales retos de este enfoque es su alta dependencia de grandes volúmenes de datos etiquetados, los cuales suelen ser costosos y difíciles de obtener. Esta limitación ha impulsado el desarrollo de variantes como el aprendizaje **semi-supervisado**, que combina un pequeño conjunto de ejemplos etiquetados con una gran cantidad de datos no etiquetados, y el aprendizaje débilmente supervisado, que trabaja con etiquetas inexactas (Russell y Norvig, 2021). Estos métodos buscan cerrar la brecha entre el aprendizaje supervisado y el no supervisado, reduciendo la necesidad de supervisión manual intensiva sin comprometer el desempeño del modelo.

¿Sabía que...?

OpenAI uso un extenso sistema de etiquetado humano (incluyendo cientos o hasta miles de contratistas, no hay cifras oficiales pero se estiman que fueron unos siete mil) para entrenar y perfeccionar sus modelos GPT y ChatGPT, especialmente mediante técnicas como RLHF (*Reinforcement Learning from Human Feedback*). Con esa retroalimentación humana se califican respuestas del modelo y generan modelos de recompensa. Estas calificaciones se usan para ajustar el modelo mediante algoritmos como PPO, refinándolo para ofrecer respuestas más coherentes y seguras.

Para el cierre de esta sección, la Figura 6 muestra las etapas prácticas de la construcción de un modelo de aprendizaje automático, desde la recolección o elección de los datos a trabajar, la exploración y limpieza (para lo cual también existen técnicas especificadas), la clasificación entre las muestras correspondientes entre el grupo de entrenamiento y el grupo con el que se espera comprobar los patrones de obtenidos. Finalmente, las diferentes métricas que permiten medir la calidad del modelo y las posibilidades que existen de ajustar o no los parámetros correspondientes para esos ajustes de calidad.

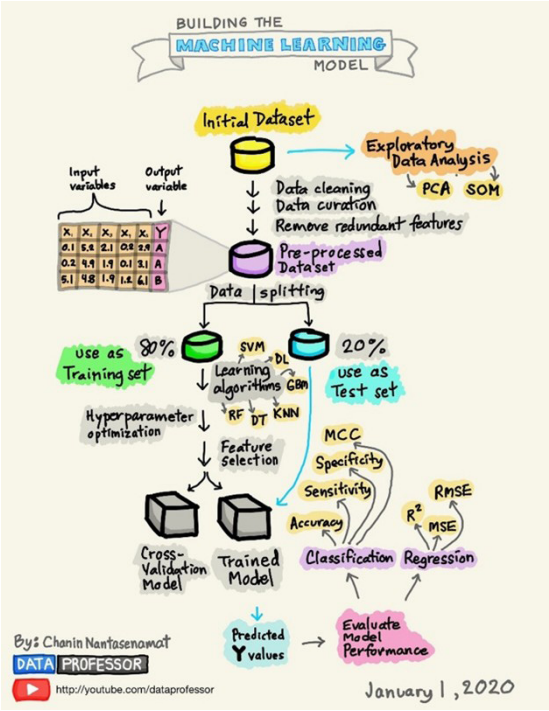


Figura 6. Construcción del Modelo de Aprendizaje Automático
Fuente: Python para Ciencia de Datos: Aprendizaje Automático (2020)

4. Problemas y algoritmos del aprendizaje no supervisado

El aprendizaje no supervisado es una técnica dentro del aprendizaje automático que se enfoca en descubrir patrones ocultos en datos que no tienen etiquetas. A diferencia del aprendizaje supervisado, donde los datos vienen con respuestas correctas, el aprendizaje no supervisado trabaja con datos sin etiquetas, lo que significa que el algoritmo debe identificar por sí mismo las estructuras o patrones presentes en los datos. Como lo mencionan Hastie *et al.* (2009): el aprendizaje no supervisado busca encontrar patrones ocultos en datos sin etiquetas.

Según James *et al.* (2013) se trata de descubrir cosas interesantes sobre las mediciones de sus variables de entrada, $X_1, X_2, \ldots X_p$. Esto incluye tareas como:

- Comprender **similitudes y relaciones**: agrupar individuos u observaciones en función de sus características.
- Descubrir subgrupos o **conglomerados**: identificar estructuras inherentes en los datos.

- **Visualización de datos**: encontrar formas informativas de representar y visualizar los datos, especialmente en entornos de alta dimensión donde la visualización directa es difícil.
- **Preprocesamiento de datos**: transformación de los datos antes de aplicar técnicas supervisadas.

4.1. Conglomerados o clusters

Uno de los problemas más comunes en el **aprendizaje no supervisado** son los conglomerados (o clustering). Este proceso consiste en dividir un conjunto de datos en grupos o clústeres, donde los datos dentro de cada grupo son más similares entre sí que a los datos de otros grupos. Un algoritmo muy utilizado para el agrupamiento es el **k-means**, que organiza los datos en k grupos basándose en la cercanía de los puntos de datos a los centros de los clústeres. Este método es útil en aplicaciones como la segmentación de clientes y la identificación de patrones en imágenes.

La Figura 7 es un ejemplo visual que ilustra cómo funcionan los métodos de agrupamiento. En el gráfico de la izquierda se muestra una distribución en dos dimensiones que permite observar cómo se dispersan las observaciones de un conjunto de datos. Por ejemplo, los puntos E y F, o A y B, se encuentran muy cerca entre sí, lo cual indica que sus valores tanto en el eje X como en el eje Y son bastante similares.

Los algoritmos de agrupamiento buscan precisamente crear grupos de observaciones con características similares. Estas relaciones también pueden verse en el dendrograma (grafico de la derecha), donde, de abajo hacia arriba, se unifican las observaciones gradualmente según su cercanía, siguiendo una estructura jerárquica.

Este gráfico nos ayuda a entender cómo las técnicas de agrupamiento identifican clústeres formados por observaciones con valores semejantes.

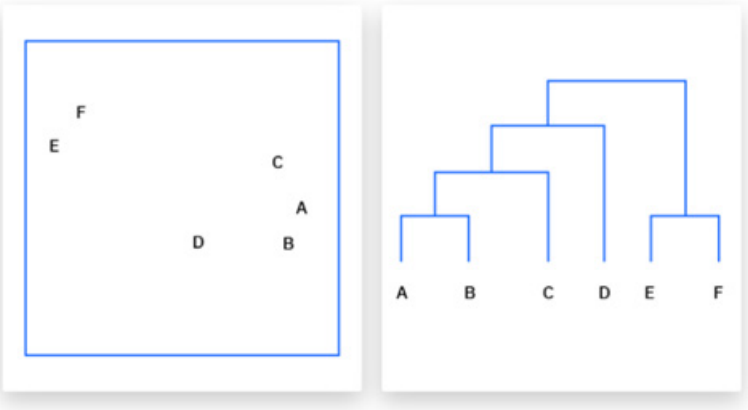


Figura 7. Clustering o agrupamiento
Fuente: tomado de IBM. (s.f.)

Cómo mejorar...

En el libro An Introduction to Statistical Learning (James *et al*., 2013) se explica el funcinamiento del dendrograma. De forma resumida, cada hoja en la parte inferior del árbol representa una observación individual. A medida que se sube en el gráfico, estas observaciones comienzan a agruparse, en primer lugar, se fusionan aquellas más parecidas entre sí, y al final, esas fusiones se van combinando con otras observaciones o grupos. Los invito a profundizar en la lectura para aprender mas sobre el funcionamiento de esta herramienta visual para el análisis de conglomerados.

Según James *et al.* (2013), existen al menos tres enfoques principales de algoritmos enfocados en la identificación de clústeres o conglomerados: los métodos particionales, los métodos basados en densidad y los métodos jerárquicos. En las siguientes secciones se profundiza en cada una de estas categorías siguiendo el enfoque de los autores.

4.1.1. Clustering particional

Este es uno de los enfoques más conocidos, la idea principal es dividir el conjunto de observaciones en un número de grupos. El algoritmo más representativo de este tipo es **K-means**, el cual se enfoca en encontrar *centroides* que representen a cada clúster y asignar los puntos al grupo más cercano.

Por ejemplo, imagine que tenemos un conjunto de datos con la altura y el peso de muchas personas. El algoritmo **K-means** se encarga de encontrar tres grupos (valor k) asumamos que son: personas de baja, media y alta estatura y peso basándose en la proximidad entre observaciones.

Inicialmente, el algoritmo asigna cada observación al grupo más cercano, según la distancia a los centroides iniciales. Luego, se evalúa si las observaciones están correctamente agrupadas en términos de distancia. Luego, el algoritmo recalcula los centroides de cada grupo y repite este proceso hasta que las asignaciones de grupo dejan de cambiar. Este algoritmo es bastante popular, pero puede tener limitaciones importantes como:

- Generar soluciones poco útiles cuando existen valores atípicos
- Requiere que los datos sean estandarizados previamente
- Debe conocer previamente el valor de k, es decir, la cantidad de clústeres antes de correr el algoritmo.

4.1.2. Clustering jerárquico

El **clustering jerárquico** no requiere especificar cuántos grupos se quieren al inicio, como si se requiere en el algorimto de k-means. En este caso, este método construye una estructura tipo árbol que muestra cómo las observaciones pueden agruparse progresivamente (tal como se mostró al inicio del apartado 4.1. Conglomerados o Clusters.

Imagínalo como organizar una colección de fotografías, puede que las fotos sean organizadas primero por año, luego por eventos, y después por personas. Así, cada nivel da lugar a una estructura más general. Técnicamente, esto se visualiza en un **dendrograma**, un gráfico en forma de árbol donde se puede observar en qué punto se fusionan los grupos.

Existen varios beneficios del **clustering jerárquico** entre los que destaca:

- Su capacidad para ofrecer diferentes niveles de agrupación sin necesidad de repetir el proceso.
- Como científicos de datos se puede cortar el dendrograma a la altura que le interese (línea horizontal sobre el árbol), según cuántos grupos se desee.
- Cuando no se conozca a detalle el contexto de negocio o no haya un criterio claro sobre la necesidad de crear los grupos, esta técnica puede permitirle hacerse una idea de cómo se agrupan los datos en función de su distancia.

4.1.3. Clustering por densidad

El tercer enfoque es el **clustering por densidad**, como el **algoritmo DBSCAN**. Este método parte de la idea de que los grupos de datos se manifiestan como regiones densas separadas por regiones menos densas o vacías.

Piense en observar una ciudad desde el aire de noche: las luces representan puntos de datos. Las zonas densamente iluminadas (como los barrios) formarían clústeres, y las zonas oscuras serían los límites naturales entre ellos. **DBSCAN** agrupa los puntos que están cerca unos de otros y deja fuera los puntos aislados, que considera ruido.

Una de las ventajas principales de este enfoque es que no necesita saber cuántos grupos hay, elmismo algoritmo es capaz de descubrir clústeres con formas arbitrarias, lo que lo hace ideal para datos complejos o con anomalías. Sin embargo, requiere definir algunos parámetros como la *distancia mínima entre puntos* y el *número mínimo de vecinos*, los cuales pueden ser sensibles a la escala de los datos.

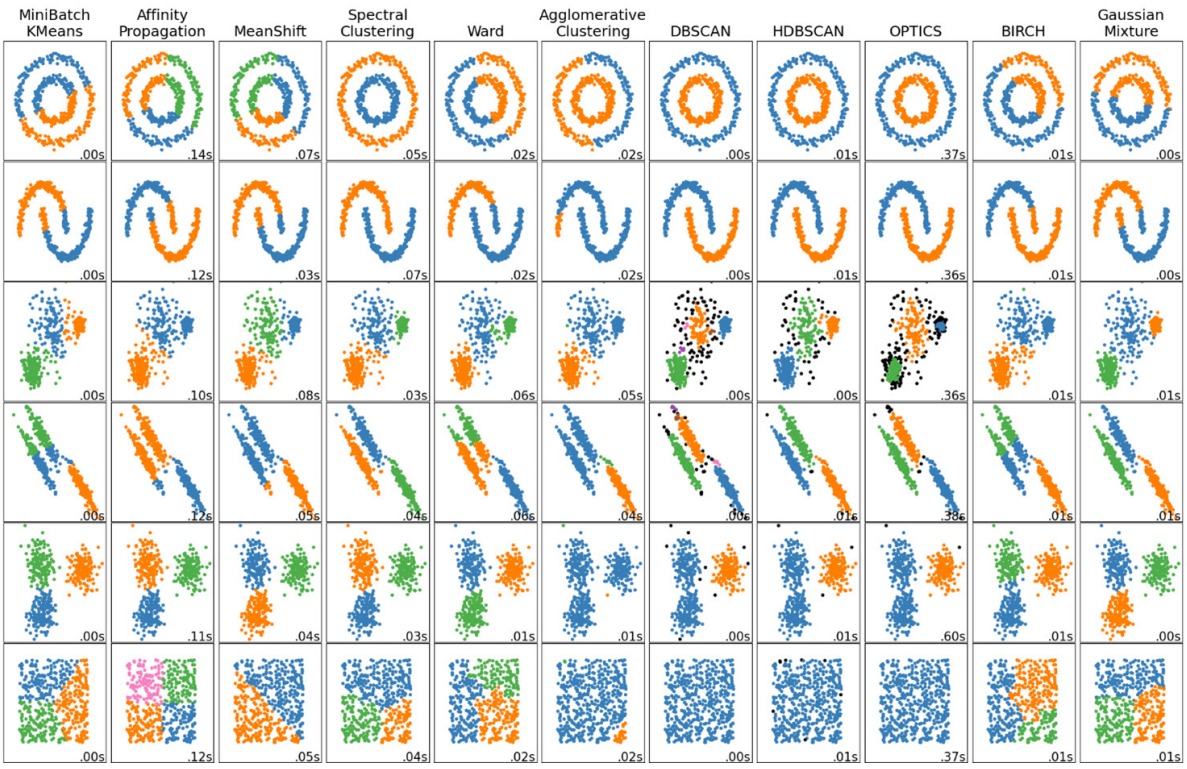


Figura 8. Comparación de algoritmos de clustering implementados en Scikit-learn
Fuente: tomada de Sklearn Scikit-learn developers (s.f.)

Una de las librerías más populares para aprendizaje automático en Python, Scikit-learn, ofrece una visualización comparativa de los algoritmos de clustering más utilizados. En la Figura 8, se puede observar cómo cada algoritmo responde ante diferentes distribuciones de datos.

En esta lectura se cubrieron tres de estos algoritmos, este recurso permite comprender de forma clara cómo su desempeño varía según la forma y estructura del conjunto de datos. Se recomienda visitar el sitio oficial de Scikit-learn, una librería especializada en algoritmos e implementaciones de aprendizaje automático en Python, para explorar más ejemplos y documentación.

Nótese además que los análisis asociados con algoritmos de conglomerados o clustering se presentan normalmente en visualizaciones de dos dimensiones, existen múltiples técnicas que permiten llevar conjuntos de datos con una alta dimensionalidad (muchas variables) a un espacio menor (menos variables) manteniendo una alta fidelidad a las relaciones de las observaciones iniciales. En la siguiente sección se mencionan algunas de las técnicas más populares.

4.2. Reducción de dimensiones

La **reducción de dimensionalidad** es un proceso que busca simplificar los datos al reducir el número de variables consideradas, mientras se conserva la mayor cantidad de información relevante. La **reducción de dimensionalidad** es especialmente útil para visualizar datos de alta dimensión y para mejorar la eficiencia de los algoritmos de aprendizaje automático. Un algoritmo popular para este propósito es el análisis de componentes principales (PCA), que transforma los datos a un nuevo espacio de menor dimensión, maximizando la varianza de los datos proyectados.

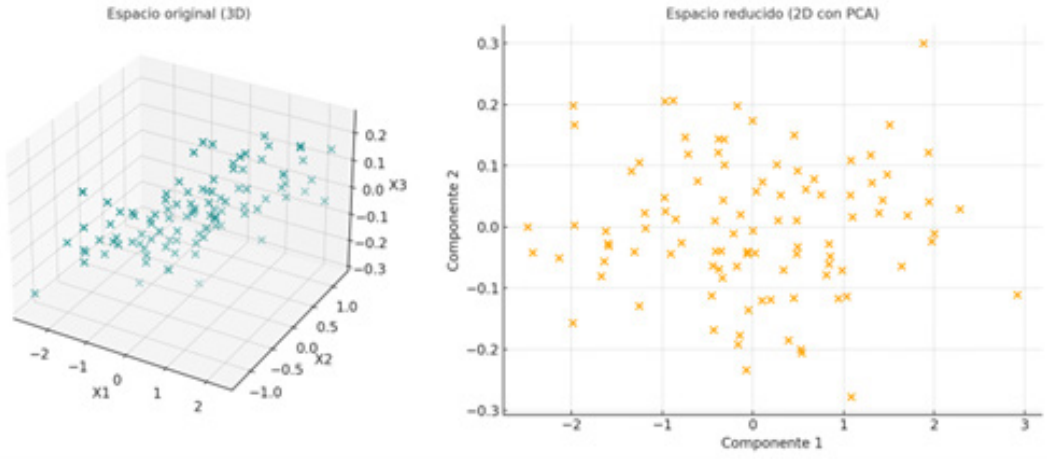


Figura 9. Análisis de componentes principales
Fuente: elaboración propia

En la Figura 9 se ejemplifica como a partir de un conjunto de datos de tres dimensiones es posible pasar a un nuevo espacio bidimensional, manteniendo un alto grado de fidelidad respecto a las relaciones entre las observaciones en los datos originales.

De forma resumida estas son las cinco etapas de este algoritmo:

1. **Centrar los datos:** lo primero que hace el algoritmo es centrar los datos, es decir, restar el promedio de cada variable a sus valores correspondientes. Esto garantiza que todas las variables tengan media cero y evita que el primer componente simplemente capture un desplazamiento. Por ejemplo, si una variable representa ingresos en millones y la otra representa edades, la escala puede sesgar los resultados si no se ajustan adecuadamente.
2. **Calcular la matriz de covarianza:** con los datos centrados, se construye la matriz de covarianza, que captura cómo varían conjuntamente las variables. Si dos variables tienen una covarianza alta y positiva, eso indica que aumentan juntas. Si es negativa, una aumenta mientras la otra disminuye.
3. **Obtener los autovalores y autovectores:** en este paso, se realiza una descomposición espectral de la matriz de covarianza. Lo que significa que se debe encontrar los autovalores (que indican cuánta varianza explica cada componente) y sus correspondientes autovectores (que indican las direcciones de esos componentes en el espacio original).

- El primer autovector (asociado al mayor autovalor) es la dirección que explica la mayor cantidad de varianza en los datos.
- El segundo autovector es ortogonal al primero y explica la siguiente mayor varianza, y así sucesivamente.

4. **Seleccionar los componentes principales:** se seleccionan los primeros k autovectores según los autovalores más grandes, de modo que juntos expliquen un porcentaje alto de la varianza (por ejemplo, 90% o 95%).
5. **Proyectar los datos al nuevo espacio:** finalmente, se proyectan las observaciones originales sobre este nuevo sistema de ejes, lo que da como resultado una versión reducida del dataset. Estas nuevas variables son combinaciones lineales de las variables originales, y tienen la ventaja de estar no correlacionadas entre sí.

4.3. Limitaciones

Aunque los algoritmos de clustering son herramientas valiosas para explorar datos sin etiquetar, tienen algunas limitaciones importantes que deben tenerse en cuenta, sobre todo cuando se usan con fines exploratorios. A diferencia del **aprendizaje supervisado**, aquí no hay una *respuesta correcta* con la cual comparar los resultados errores (Hastie et al., 2009). Esto significa que muchas veces la evaluación depende más de la interpretación del quien realiza el análisis que de una métrica objetiva. Como explican los autores, incluso técnicas bien establecidas como PCA se vuelven "ad hoc" cuando se usan únicamente para explicar la variabilidad en los datos, sin una tarea supervisada que permita validar su utilidad.

Por otro lado, los resultados pueden cambiar drásticamente según las decisiones iniciales: el número de clústeres que se especifique, el tipo de métrica de disimilitud que se utilice, o incluso el orden en que se presentan los datos. Una práctica habitual es probar múltiples configuraciones y buscar patrones que se mantengan consistentes. Sin embargo, no siempre ocurre y si ocurre, no hay garantías, los autores mencionas que se obtiene es un punto de partida, no una conclusión definitiva.

Se listan algunas limitaciones clave a tener en cuenta:

- No existe una métrica objetiva de calidad universal. El éxito se mide en términos de interpretabilidad o utilidad práctica, no de exactitud.
- Alta sensibilidad a parámetros y decisiones iniciales.
- Pequeñas modificaciones en los datos pueden llevar a soluciones completamente distintas, lo que pone en duda la estabilidad de los resultados.
- Problemas en espacios de alta dimensionalidad, donde ciertos métodos pierden efectividad al tratar de estimar estructuras complejas.

En clustering se pueden encontrar agrupaciones que parecen tener sentido por color o forma, pero no hay una forma objetiva de saber si la implementación va por buen camino. Por eso, es clave entender que estos métodos ofrecen hipótesis sobre la estructura de los datos, no verdades absolutas.

En síntesis...

El aprendizaje automático, es una capa de la inteligencia artificial, entrena a a las máquinas para aprender y resolver problemas complejos sin tener que programarlos explícitamente. Su fundamentos se centran en tres elementos clave: datos, modelos y algoritmos. Los datos, son los que nutren a los modelos (representaciones matemáticas) que, a su vez, son ajustados por algoritmos para aprender de la información y hacer predicciones o clasificaciones.

Existen distintas formas de aprendizaje, entre ellas el supervisado, que aborda problemas de clasificación (asignar etiquetas) y regresión (predecir valores continuos). Es extremadamente importante que los modelos sean capaces de *generalizar*, es decir, predecir correctamente con datos nuevos. Dentro de la lectura se explicó la importancia de la división de los datos en conjuntos de entrenamiento y prueba, para encontrar el *ajuste óptimo* y que evite el sobreajuste.

5. Conclusiones

El éxito del **aprendizaje automático** no está únicamente en la sofisticación de los algoritmos, sino en una comprensión profunda de los datos y el conocimiento de negocio en el que se aplican. La disponibilidad de grandes volúmenes de datos no garantiza resultados útiles; es extremadamente importante analizar su calidad, relevancia y posibles sesgos, ya que estos pueden replicarse en las predicciones del modelo. A modo de cierre, los estudiantes se deben cuestionar la procedencia de los datos, entender su contexto y reconocer sus limitaciones.

El conocimiento del negocio es vital para generar valor real sobre la organización. Un modelo de **aprendizaje automático** es una herramienta para resolver un problema específico. Incluso el algoritmo más avanzado puede fallar si no se comprende a fondo el problema y las implicaciones en la empresa. Esto significa que se debe ir más allá de los indicadores técnicos del modelo. La asociación entre los expertos en datos y los expertos del negocio, es fundamental para exprimir el potencial del aprendizaje automático en soluciones prácticas y significativas.

Dentro de esta lectura no se profundizó sobre los procesos de evaluación de los modelos y técnicas más avanzadas como las de aprendizaje profundo. El enfoque se mantuvo en los conceptos fundamentales del aprendizaje automático, dejando por fuera aspectos como las métricas de desempeño más complejas y las arquitecturas avanzadas de redes neuronales. Estos temas, por su nivel de especialización, se consideran adecuados para abordarse de forma complementaria al contenido aquí presentado. En las referencias incluidas, se proponen libros y documentos que desarrollan estos aspectos con mayor profundidad. Se recomienda revisar dichas lecturas una vez se hayan puesto en práctica los conceptos básicos expuestos en esta lectura, de modo que los fundamentos estén claros y bien establecidos.

Referencias

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature, 542*(7639), 115–118.

Géron, A. (2019). *Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow* (2nd ed.). O'Reilly Media.

Hastie, T., Tibshirani, R., & Friedman, J. H. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (Vol. 2, pp. 1–758). Springer.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning: With applications in R* (Corrected at 8th printing 2017). Springer. https://doi.org/10.1007/978-1-4614-7138-7

Maldonato, M., & Dell'Orco, S. (2011). *Decision making styles and adaptive algorithms for human action. Psychology, 2*(8), 811–816.

Mitchell, T. M. (1997). Does machine learning really work? *AI Magazine, 18*(3), 11–11.

Murphy, K. P. (2012). *Machine learning: A probabilistic perspective.* MIT Press.

Russell, S., & Norvig, P. (2021). *Artificial intelligence: A modern approach.* Prentice Hall.

Saldaña Sánchez, E. (2021). *Desarrollo de una herramienta basada en machine learning para la ayuda en la toma de decisiones*.

Statista. (2025). Data center – *Worldwide. Statista*. https://www-statista-com.ezproxy.humber.ca/outlook/tmo/data-center/worldwide

Referencias de imágenes

MathWorks. (s.f.). Cross-validation. https://uk.mathworks.com/discovery/cross-validation.html

IBM. (n.d.). Unsupervised learning. https://www.ibm.com/es-es/think/topics/unsupervised-learning

Statista. (2025). Data Center – Worldwide. https://www.statista.com/outlook/tmo/data-center/worldwide

Scikit-learn developers. (n.d.). A comparison of the clustering algorithms in scikit-learn [Imagen]. Scikit-learn. https://scikit-learn.org/stable/modules/clustering.html#overview-of-clustering-methods

Zapata, J. (s.f.). Python para ciencia de datos: Aprendizaje automático. Recuperado de https://joserzapata.github.io/courses/python-ciencia-datos/ml/



Información técnica

Módulo: Inteligencia Artificial

Unidad 4: Aprendizaje Automático

Autor: Mauricio Alejandro Cano Niño

Asesora Pedagógica: Natalia Carolina Ramos Martínez

Diseñador Gráfico: Daniel Rodríguez Reyes

Este material es de uso institucional.
Prohibida su reproducción total o parcial.